

Raport TIMKoD – Lab 3 i 4 – Entropie warunkowe języków naturalnych

Rozpoznawanie czy dany tekst to język

Jakub Biernat 160248

I. Wylicz entropię znaków i słów oraz ich entropie warunkowe kolejnych rzędów dla próbki języka angielskiego (plik `norm_wiki_en.txt`).

Plik:	Entropia znaków:	Entropia słów:
<i>norm_wiki_en.txt</i>	4.174	7.736
Rząd n:	Entropia warunkowa znaków rzędu n:	Entropia warunkowa słów rzędu n:
1	3.222	2.390
2	2.286	0.419
3	1.314	0.063
4	0.733	0.034
5	0.465	0.025

II. Następnie wylicz entropię znaków i słów oraz ich entropie warunkowe kolejnych rzędów dla próbki języka łacińskiego (plik `norm_wiki_la.txt`).

Plik:	Entropia znaków:	Entropia słów:
<i>norm_wiki_la.txt</i>	4.063	9.007
Rząd n:	Entropia warunkowa znaków rzędu n:	Entropia warunkowa słów rzędu n:
1	3.262	1.262
2	2.352	0.075
3	1.428	0.002
4	0.797	0.000
5	0.456	0.000

III. Korzystając z zaobserwowanych wartości entropii warunkowej odpowiedz na pytanie, czy następujące pliki zawierają język naturalny.

Plik:	Entropia znaków:	Entropia słów:
<i>sample0.txt</i>	4.274	7.457
Rząd n:	Entropia warunkowa znaków rzędu n:	Entropia warunkowa słów rzędu n:
1	2.910	3.220
2	1.893	0.150
3	1.171	0.004
4	0.807	0.000
5	0.579	0.000
Werdykt i uzasadnienie: Plik sample0.txt nie jest językiem naturalnym, ponieważ wartość entropii warunkowej słów spada bardzo szybko, a dla rządów >3 jest równa zero, więc nie niesie żadnej informacji.		

Plik:	Entropia znaków:	Entropia słów:
<i>sample1.txt</i>	4.019	8.159
Rząd n:	Entropia warunkowa znaków rzędu n:	Entropia warunkowa słów rzędu n:
1	3.038	1.953
2	2.326	0.349
3	1.384	0.056
4	0.774	0.011
5	0.498	0.005
Werdykt i uzasadnienie: Plik sample1.txt jest językiem naturalnym, ponieważ wartość entropii warunkowej słów spada zgodnie z oczekiwaniami, a dla rządów >3 nie jest zerowa, więc niesie jakąś informację.		

Plik:	Entropia znaków:	Entropia słów:
<i>sample2.txt</i>	4.000	7.520
Rząd n:	Entropia warunkowa znaków rzędu n:	Entropia warunkowa słów rzędu n:
1	3.003	3.070
2	2.331	0.390
3	1.583	0.025
4	1.010	0.000
5	0.614	0.000
Werdykt i uzasadnienie: Plik sample2.txt nie jest językiem naturalnym, ponieważ wartość entropii warunkowej słów spada bardzo szybko, a dla rządów >3 jest równa zero, więc nie niesie żadnej informacji.		

Plik:	Entropia znaków:	Entropia słów:
<i>sample3.txt</i>	3.835	7.198
Rząd n:	Entropia warunkowa znaków rzędu n:	Entropia warunkowa słów rzędu n:
1	3.016	2.909
2	2.197	0.446
3	1.326	0.097
4	0.808	0.0275
5	0.560	0.010
Werdykt i uzasadnienie: Plik sample3.txt jest językiem naturalnym, ponieważ wartość entropii warunkowej słów spada zgodnie z oczekiwaniami, a dla rządów >3 nie jest zerowa, więc niesie jakąś informację.		

Plik:	Entropia znaków:	Entropia słów:
<i>sample4.txt</i>	4.251	9.670
Rząd n:	Entropia warunkowa znaków rzędu n:	Entropia warunkowa słów rzędu n:
1	4.144	0.588
2	3.376	0.002
3	1.335	0.000
4	0.168	0.000
5	0.011	0.000
Werdykt i uzasadnienie: Plik sample4.txt nie jest językiem naturalnym, ponieważ wartość entropii warunkowej słów jest bardzo niska oraz spada bardzo szybko, a dla rządów >2 jest równa zero, więc nie niesie żadnej informacji.		

Plik:	Entropia znaków:	Entropia słów:
<i>sample5.txt</i>	4.434	10.119
Rząd n:	Entropia warunkowa znaków rzędu n:	Entropia warunkowa słów rzędu n:
1	3.492	0.000
2	2.802	0.000
3	1.549	0.000
4	0.632	0.000
5	0.232	0.000
Werdykt i uzasadnienie: Plik sample5.txt nie jest językiem naturalnym, ponieważ wartość entropii warunkowej słów jest równa zero, więc nie niesie żadnej informacji.		